


浪费大语言模型 (LLM) 训练算力 = 更好的损失 (Loss)?

Vuk Rosić*

 vukrosic



这些结果可以用来通过最优的正交化约束 (orthogonalization constraints) 加速大语言模型 (LLM) 的预训练。

主要结论是——你越是强制 LLM 的各个部分保持正交 (orthogonal)，它在早期的学习速度就越慢，但在后期的学习速度就越快。

较少的正交化会使得更多的维度坍塌 (collapse) 到接近 0 的状态，这使得损失 (loss) 在早期下降得更快，但这在训练的后期会成为一个瓶颈。

我运行了三个 LLM 训练实验，通过 Muon 优化器测试不同的正交化约束。Muon 的工作原理是强制梯度矩阵的行正交（独立）。在将梯度张量交由 Muon 处理之前，通过改变其形状 (reshaping)，我们可以重新定义什么是“行 (row)”，从而控制什么必须独立于什么。

我将这些约束应用于一个约 6.5 亿 (650M) 参数的 LLM 的查询和键投影 (Query and Key projections, W_Q 和 W_K)。

*感谢 Novita AI 为本研究提供计算资源。

以下是我比较的 3 种设置：

- 1. **标准 Muon (Baseline, 基线)**：全局正交性 (Global orthogonality)。每一个注意力头 (head) 的每一个单一维度都必须与其它所有事物独立。这强制了最大程度的多样性。
- 2. **模式 1 (Input-Shared / HeadOrtho, 输入共享)**：共享子空间 (Shared subspace)。它强制第 i 个特征维度独立于第 j 个特征维度，但允许不同头中具有相同索引的特征完全相同。不同的头可以自然地对齐并协作。
- 3. **模式 3 (Inter-Head, 头间)**：独立头。作为整体的头 1 必须与作为整体的头 2 正交。然而，单个头内部的特征可以完全相关。

请在下面找到更详细的解释。

结果 (The Results)

我追踪了训练损失 (Training Loss) 和参与率 (Participation Ratio, PR)，参与率是一种测量查询和键投影矩阵的“有效秩 (effective rank)”的方法。对于具有奇异值 σ_i 的矩阵，PR 的计算公式为：

$$PR = \frac{(\sum \sigma_i^2)^2}{\sum \sigma_i^4} \tag{1}$$

如果 PR 保持在高位，矩阵就充分利用了其多样化的容量 (许多维度都远离 0)。如果 PR 下降，意味着表示正在坍缩和变得相关 (某些维度接近 0)。


我们训练了 3 亿 (300 million) 个词元 (tokens)。(注：对于一个完整的 LLM 来说这太短了，但在我们扩大算力规模之前，它提供了强有力的初步信号)。

3 亿个词元时的定量结果 (Quantitative Results at 300M Tokens)

指标 (Metric)	模式 1 (Input-Shared)	模式 3 (Inter-Head)	基线 (Standard Muon)
最终训练损失 (Final Train Loss)	3.073	3.100	3.096
最终参与率 (Final PR)	31.6	26.1	57.2


图表和表格告诉我们什么 (What the Graphs and Table Tell Us)

如果我们分析上面的数据，会发现一些非常明显的（并且有些极其怪异的）行为：




这张轨迹图追踪了每种模式从开始到结束的路径。请注意，基线 (*Baseline*, 青色) 在损失下降的同时，其参与率 (*PR*) 也在缓慢流失。相比之下，模式 1 (橙色) 在早期经历了突然的秩坍塌 (*rank collapse*)，但随着它获得更低的整体损失，它的 *PR* 开始缓慢恢复并向右偏移。为了看到最终结果，需要更长时间的训练（我们目前正在处理更多的算力）。

1. Muon 非常擅长保持高秩 (Forced Diversity, 强制多样性)



- **基线 (青色方块)** 正面对抗了模型自然简化的趋势。通过在所有部分强制执行严格的、大规模的正交性，标准 Muon 证明它非常擅长保持高参与率 (~ 57.2)。但是，它并没有被完美地保留下来——随着时间的推移，即使是基线也表现出缓慢的、持续的秩衰减。
- 相比之下，当我们放松头内部的约束时 (模式 1 和模式 3 的正交性要求较低)，模型非常乐意在早期抛弃其多样性，并经历了大规模的秩坍塌。但在最初的崩溃之后，它们的 PR 逐渐开始缓慢攀升，并在我们训练窗口的末期积极改善。需要更多的训练才能看到那些 PR 最终会停在哪里。

2. 坍塌的头在早期给出了更好的损失，但似乎基线正在追赶！



- 尽管早期经历了大规模的秩坍塌，但模式 1 最初下降得最快，并且目前保持着最低的训练损失 (3.073)。
- 然而，虽然模式 1 取得了早期的领先优势，但基线强制执行的多样性似乎正在获得回报。模式 1 和基线之间的损失差异在 -0.16 左右达到峰值，但此后一直在缩小。

Muon 优化中的头正交性：实验设置 (Head Orthogonality in Muon Optimization: Experimental Setup)

技术细节：实验设置与方法论 (Technical Details: Experimental Setup & Methodology)

(本节详细介绍了总结的上述三种模式背后的数学结构)。

为了从数学上理解这些消融实验 (ablations)，我们要看看在 Muon 固有的行正交化之前，重塑 (rearranging) 梯度张量 G 是如何影响哪些参数被迫保持独立的。

1. 方法论：正交性的三种模式 (Methodology: Three Modes of Orthogonality)

我们研究了牛顿-舒尔茨 (Newton-Schulz) 迭代期间梯度张量 G 的形状是如何影响键/查询投影 (Key/Query projections, $W_{QK} \in \mathbb{R}^{H \cdot d_k \times d_{model}}$) 的学习动态的。

维度约束总结 (Summary of Dimensional Constraints)

核心区别在于，哪些组件被强制放入相同的“行”中（并因此被迫与其他组件正交），而哪些组件则处于相同的“向量”中（从而被允许对齐）。

模式 (Mode)	重塑目标 (Reshape Target)	正交层次 (Hierarchy of Ortho)	有效约束 (Effective Constraint)
基线 (Baseline)	$(H \cdot d_k) \times d_{model}$	一切 $\perp$ 一切	最强约束。 最大化头多样性。
模式 1 (Mode 1)	$d_k \times (H \cdot d_{model})$	行索引 $\perp$ 行索引	共享子空间。 头被水平拼接。
模式 3 (Mode 3)	$H \times (d_k \cdot d_{model})$	头 $\perp$ 头	独立头。 内部行可对齐。

- **基线**指示：“每一个单独的头部的权重投影矩阵的每一行 (参数向量) 都必须是唯一的，并且与所有其他行正交。”
- **模式 1** 指示：“头 1 的第 i 行和头 2 的第 i 行属于同一长向量。它们必须垂直于任何第 j 行 ($i \neq j$)，但头 1 和头 2 可以在第 i 维度上使用相同的权重。”
- **模式 3** 指示：“头 1 必须作为一个整体（其所有行相结合）正交于头 2 (作为一个整体)。与基线不同，它并不关心头 1 内部的行是否相似，只要‘头 1 子空间’正交于‘头 2 子空间’即可。”

1.1 基线：全局矩阵正交性 (Baseline: Global Matrix Orthogonality)

标准 **Muon** (Standard Muon) 将整个参数矩阵视为一个单独的 2D 张量。

$$G_{\text{base}} \in \mathbb{R}^{(H \cdot d_k) \times d_{model}}$$

其中：

- H 是注意力头的数量（例如：16）。
- d_k 是每个头的维度（例如：128）。

- d_{model} 是输入的隐藏层维度（例如：2048）。
- 每个元素 $W_{QK}^{h,i}$ 代表头 h 的 **QK** 投影矩阵的第 i 个行向量。其大小为 d_{model} 。

优化器使这一个巨大矩阵的行正交化。

- **约束：** 每一行（每一个头的一个维度）都要与组合矩阵中的其他所有行进行正交化。
- **效果：** 这强制要求所有 $H \cdot d_k$ 个输出维度同时存在一个整体的多样性约束。

示例 ($H = 2, d_k = 2$): 所有事物必须与其他所有事物正交。每行是一个大小为 d_{model} 的权重向量。

矩阵行 (Matrix Row)	代表的权重向量 (Weight Vec)	正交于 (Orthogonal to:)	含义 (Meaning)
行 1	$W_{QK}^{1,1}$	行 2, 3, 4	$W_{QK}^{1,1} \neq W_{QK}^{1,2}, W_{QK}^{2,1}$ 等
行 2	$W_{QK}^{1,2}$	行 1, 3, 4	头 1 内部的特征正交。
行 3	$W_{QK}^{2,1}$	行 1, 2, 4	头 2 正交于头 1。
行 4	$W_{QK}^{2,2}$	行 1, 2, 3	头 2 内部的特征正交。

可视矩阵 (Visual Matrix) ($4 \times d_{model}$):

$$G_{\text{base}} = \begin{bmatrix} w_{1,1,1} & w_{1,1,2} & \dots & w_{1,1,D} \\ w_{1,2,1} & w_{1,2,2} & \dots & w_{1,2,D} \\ w_{2,1,1} & w_{2,1,2} & \dots & w_{2,1,D} \\ w_{2,2,1} & w_{2,2,2} & \dots & w_{2,2,D} \end{bmatrix} \begin{matrix} \leftarrow W_{QK}^{1,1} \text{ (头 1, 行 1)} \\ \leftarrow W_{QK}^{1,2} \text{ (头 1, 行 2)} \\ \leftarrow W_{QK}^{2,1} \text{ (头 2, 行 1)} \\ \leftarrow W_{QK}^{2,2} \text{ (头 2, 行 2)} \end{matrix}$$

所有 4 行都会彼此正交化。

1.2 模式 1: 输入共享的正交性 (Mode 1: Input-Shared Orthogonality (“HeadOrtho”))

我们重塑梯度，以将“头维度 (head dimension)”与“特征维度 (feature dimension)”分离开，并将共享输入空间上的 d_k 个特征维度正交化。

$$G_{\text{mode1}} \in \mathbb{R}^{d_k \times (H \cdot d_{model})}$$

- **约束**：第 i 个特征维度与第 j 个特征维度正交化，该向量是聚合了所有头获得的。
- **结构**：这将 H 个头视为在构成一个共享的 d_k 维子空间。在这相同的特征维度上，并不强制不同头之间正交。

示例 ($H = 2, d_k = 2$)：我们只重塑为 **2** 个大行 ($d_k = 2$)。每一行是所有头中该特征行的拼接 (*concatenation*)。

矩阵行 (Matrix Row)	代表的拼接向量 (Concat Vec)	正交于 (Orthogonal to:)	含义 (Meaning)
行 1	$W_{QK}^{1,1} \oplus W_{QK}^{2,1}$	行 2	行 1 子空间 $\perp$ 行 2 子空间。
行 2	$W_{QK}^{1,2} \oplus W_{QK}^{2,2}$	行 1	$W_{QK}^{1,1}$ 和 $W_{QK}^{2,1}$ 可以完全相同。

可视矩阵 (Visual Matrix) ($2 \times 2 \cdot d_{model}$):

$$G_{\text{mode1}} = \left[\begin{array}{c|c} \underbrace{w_{1,1,1} \dots w_{1,1,D}}_{W_{QK}^{1,1} \text{ (头 1)}} & \underbrace{w_{2,1,1} \dots w_{2,1,D}}_{W_{QK}^{2,1} \text{ (头 2)}} \\ \hline \underbrace{w_{1,2,1} \dots w_{1,2,D}}_{W_{QK}^{1,2} \text{ (头 1)}} & \underbrace{w_{2,2,1} \dots w_{2,2,D}}_{W_{QK}^{2,2} \text{ (头 2)}} \end{array} \right]$$

只有顶行 $\perp$ 底行。头 1 和头 2 仅仅是同一行向量中的不同列部分！

1.3 模式 3：头间正交性 (Mode 3: Inter-Head Orthogonality)

我们重塑梯度以迫使各个头彼此正交。

$$G_{\text{mode3}} \in \mathbb{R}^{H \times (d_k \cdot d_{model})}$$

- **约束**：头 i 的梯度更新向量会与头 j 进行正交化。
- **结构**：这专门针对注意力头的独立性，将每个头视为参数空间中的一个单位向量。

示例 ($H = 2, d_k = 2$)：我们重塑为只有 **2** 个大行（每个头有一个，所以 $H = 2$ ）。每一行是该头内所有特征行的拼接 (*concatenation*)。

矩阵行 (Matrix Row)	代表的拼接向量 (Concat Vec)	正交于 (Orthogonal to:)	含义 (Meaning)
行 1	$W_{QK}^{1,1} \oplus W_{QK}^{1,2}$	行 2	头 1 必须正交于头 2。
行 2	$W_{QK}^{2,1} \oplus W_{QK}^{2,2}$	行 1	头内特征可以是任何组合 (只要 $\perp$ H1)。

可视矩阵 (**Visual Matrix**) ($2 \times 2 \cdot d_{model}$):

$$G_{mode3} = \left[\begin{array}{c|c} \underbrace{w_{1,1,1} \dots w_{1,1,D}}_{W_{QK}^{1,1}} & \underbrace{w_{1,2,1} \dots w_{1,2,D}}_{W_{QK}^{1,2}} \\ \hline \underbrace{w_{2,1,1} \dots w_{2,1,D}}_{W_{QK}^{2,1}} & \underbrace{w_{2,2,1} \dots w_{2,2,D}}_{W_{QK}^{2,2}} \end{array} \right] \begin{array}{l} \leftarrow \text{头 1 参数 (Head 1 Parameters)} \\ \leftarrow \text{头 2 参数 (Head 2 Parameters)} \end{array}$$

顶行 (头 1) $\perp$ 底行 (头 2)。

2. 实验设置 (Experimental Setup)

为了比较这些模式，我们训练了一个约 6.5 亿参数的语言模型。

2.1 模型架构 (Model Architecture)

- 参数量 (**Parameters**): 约 6.5 亿 (650 Million)
- 层数 (**Layers**): 12
- 隐藏层维度 (d_{model}): 2048
- 注意力头 (**Attention Heads**): 16 (使用分组查询注意力, 含 8 个 KV 头)
- 头维度 (d_k): 128
- 序列长度 (**Sequence Length**): 2048

2.2 训练配置 (Training Configuration)

- 数据集 (**Dataset**): SmolLM-corpus。

- **训练词元 (Tokens Trained):** 3 亿 (300 Million)。
- **批次大小 (Batch Size):** 32, 梯度累积步数为 4 (等效批次大小约为 26 万 (262k) 个词元)。
- **优化器 (Optimizer):** Muon (用于 2D 参数) + AdamW (用于嵌入/归一化参数)。
- **学习率 (Learning Rate):** Muon LR 0.05, AdamW LR 0.005。

2.3 追踪的指标 (Metrics Tracked)

在整个训练过程中，我们主要监测两个指标：

1. **训练损失 (Training Loss):** 用于衡量优化的效率。
2. **参与率 (Participation Ratio, PR):** 估计键/查询投影矩阵的有效秩，以量化“秩坍塌 (Rank Collapse)”与严格正交性。

3. 结论 (Conclusion)

正如本文件第一部分进行了大量绘图并讨论的那样，全局强制正交性（基线）人为地维持了投影矩阵的秩，使得在训练开始时的优化暂时变慢。放宽这个约束从而允许自然产生相关性和结构性分组（模式 1 和模式 3），会导致秩的大幅下降，但在最初带来了极快损失下降。然而，因为基线一旦开始利用其保留的多样性就会赶上进度，所以长期来看，真实的最优归纳偏置（inductive bias）仍是一个悬而未决的问题。